Laboratorio 2

Bienvenidos de nuevo al segundo laboratorio de Deep Learning y Sistemas inteligentes. Espero que este laboratorio sirva para consolidar sus conocimientos del tema de Redes Neuronales Convolucionales.

Este laboratorio consta de dos partes. En la primera trabajaremos una Red Neuronal Convolucional paso-a-paso. En la segunda fase, usaremos PyTorch para crear una nueva Red Neuronal Convolucional, con la finalidad de que no solo sepan que existe cierta función sino también entender qué hace en un poco más de detalle.

Para este laboratorio estaremos usando una herramienta para Jupyter Notebooks que facilitará la calificación, no solo asegurándo que ustedes tengan una nota pronto sino también mostrandoles su nota final al terminar el laboratorio.

Espero que esta vez si se muestren los *marks*. De nuevo me discupo si algo no sale bien, seguiremos mejorando conforme vayamos iterando. Siempre pido su comprensión y colaboración si algo no funciona como debería.

Al igual que en el laboratorio pasado, estaremos usando la librería de Dr John Williamson et al de la University of Glasgow, además de ciertas piezas de código de Dr Bjorn Jensen de su curso de Introduction to Data Science and System de la University of Glasgow para la visualización de sus calificaciones.

In [ ]:
```
# Una vez instalada la librería por favor, recuerden volverla a comentar.
#!pip3 install -U --force-reinstall --no-cache https://github.com/johnhw/jhwuti
#!pip3 install scikit-image
```

```
Collecting https://github.com/johnhw/jhwutils/zipball/master
  Downloading https://github.com/johnhw/jhwutils/zipball/master
     \ 38.1 kB 246.1 kB/s 0:00:00
  Preparing metadata (setup.py) ... done
Building wheels for collected packages: jhwutils
  Building wheel for jhwutils (setup.py) ... done
  Created wheel for jhwutils: filename=jhwutils-1.0-py3-none-any.whl size=3382
1 sha256=6f139e2f86b1318ee2b32e662a3b7febe2e6183c7c284cff48bc5e9803f6a148
  Stored in directory: /private/var/folders/vf/44lz8h455mvflsvv9khsdx5w0000gn/
T/pip-ephem-wheel-cache-l4zfazzz/wheels/27/3c/cb/eb7b3c6ea36b5b54e5746751443be
9bb0d73352919033558a2
Successfully built jhwutils
Installing collected packages: jhwutils
Successfully installed jhwutils-1.0

[notice] A new release of pip is available: 23.1 -> 23.2.1
[notice] To update, run: python3.10 -m pip install --upgrade pip
Collecting scikit-image
  Downloading scikit_image-0.21.0-cp310-cp310-macosx_12_0_arm64.whl (12.4 MB)
     ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 12.4/12.4 MB 2.4 MB/s eta 0:00:0
000:0100:01
Requirement already satisfied: numpy>=1.21.1 in /Library/Frameworks/Python.fra
mework/Versions/3.10/lib/python3.10/site-packages (from scikit-image) (1.23.0.
dev0+1065.gf996a2b62)
Requirement already satisfied: scipy>=1.8 in /Library/Frameworks/Python.framew
ork/Versions/3.10/lib/python3.10/site-packages (from scikit-image) (1.8.0)
Requirement already satisfied: networkx>=2.8 in /Library/Frameworks/Python.fra
mework/Versions/3.10/lib/python3.10/site-packages (from scikit-image) (3.0)
Requirement already satisfied: pillow>=9.0.1 in /Library/Frameworks/Python.fra
mework/Versions/3.10/lib/python3.10/site-packages (from scikit-image) (9.1.0)
Collecting imageio>=2.27 (from scikit-image)
  Downloading imageio-2.31.1-py3-none-any.whl (313 kB)
     ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 313.2/313.2 kB 1.5 MB/s eta 0:00:
00a 0:00:01
Collecting tifffile>=2022.8.12 (from scikit-image)
  Downloading tifffile-2023.7.18-py3-none-any.whl (221 kB)
     ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 221.4/221.4 kB 2.1 MB/s eta 0:00:
00a 0:00:01
Requirement already satisfied: PyWavelets>=1.1.1 in /Library/Frameworks/Pytho
n.framework/Versions/3.10/lib/python3.10/site-packages (from scikit-image) (1.
4.1)
Requirement already satisfied: packaging>=21 in /Library/Frameworks/Python.fra
mework/Versions/3.10/lib/python3.10/site-packages (from scikit-image) (21.3)
Requirement already satisfied: lazy_loader>=0.2 in /Library/Frameworks/Python.
framework/Versions/3.10/lib/python3.10/site-packages (from scikit-image) (0.2)
Requirement already satisfied: pyparsing!=3.0.5,>=2.0.2 in /Library/Framework
s/Python.framework/Versions/3.10/lib/python3.10/site-packages (from packaging>
=21->scikit-image) (3.0.7)
Installing collected packages: tifffile, imageio, scikit-image
  WARNING: The scripts lsm2bin, tiff2fsspec, tiffcomment and tifffile are inst
alled in '/Library/Frameworks/Python.framework/Versions/3.10/bin' which is not
on PATH.
  Consider adding this directory to PATH or, if you prefer to suppress this wa
rning, use --no-warn-script-location.
  WARNING: The scripts imageio_download_bin and imageio_remove_bin are install
ed in '/Library/Frameworks/Python.framework/Versions/3.10/bin' which is not on
PATH.
  Consider adding this directory to PATH or, if you prefer to suppress this wa
rning, use --no-warn-script-location.
Successfully installed imageio-2.31.1 scikit-image-0.21.0 tifffile-2023.7.18
```

```
[notice] A new release of pip is available: 23.1 -> 23.2
[notice] To update, run: python3.10 -m pip install --upgrade pip
```

In [ ]:
```python
import numpy as np
import copy
import matplotlib.pyplot as plt
import scipy
from PIL import Image
import os
from IPython import display
from base64 import b64decode


# Other imports
from unittest.mock import patch
from uuid import getnode as get_mac

from jhwutils.checkarr import array_hash, check_hash, check_scalar, check_strir
import jhwutils.image_audio as ia
import jhwutils.tick as tick

###
tick.reset_marks()

%matplotlib inline
```

In [ ]:
```python
# Seeds
seed_ = 2023
np.random.seed(seed_)
```

In [ ]:
```python
# Hidden cell for utils needed when grading (you can/should not edit this)
# Celda escondida para utlidades necesarias, por favor NO edite esta celda
```

Información del estudiante en dos variables

- carne_1 : un string con su carne (e.g. "12281"), debe ser de al menos 5 caracteres.
- firma_mecanografiada_1: un string con su nombre (e.g. "Albero Suriano") que se usará para la declaracion que este trabajo es propio (es decir, no hay plagio)
- carne_2 : un string con su carne (e.g. "12281"), debe ser de al menos 5 caracteres.
- firma_mecanografiada_2: un string con su nombre (e.g. "Albero Suriano") que se usará para la declaracion que este trabajo es propio (es decir, no hay plagio)

In [ ]:
```python
carne_1 = "20347"
firma_mecanografiada_1 = "Alejandro Gomez"
carne_2 = "20498"
firma_mecanografiada_2 = "Gabriel Vicente"
# YOUR CODE HERE
raise NotImplementedError()
```

```
---------------------------------------------------------------------------
NotImplementedError                       Traceback (most recent call last)
/Users/alegomez/Documents/UVG/Cuarto Año/Segundo Semestre/DL/lab2.ipynb Cell 8
in <cell line: 6>()
      <a href='vscode-notebook-cell:/Users/alegomez/Documents/UVG/Cuarto%20An%
CC%83o/Segundo%20Semestre/DL/lab2.ipynb#X10sZmlsZQ%3D%3D?line=3'>4</a> firma_m
ecanografiada_2 = "Gabriel Vicente"
      <a href='vscode-notebook-cell:/Users/alegomez/Documents/UVG/Cuarto%20An%
CC%83o/Segundo%20Semestre/DL/lab2.ipynb#X10sZmlsZQ%3D%3D?line=4'>5</a> # YOUR
CODE HERE
----> <a href='vscode-notebook-cell:/Users/alegomez/Documents/UVG/Cuarto%20An%
CC%83o/Segundo%20Semestre/DL/lab2.ipynb#X10sZmlsZQ%3D%3D?line=5'>6</a> raise N
otImplementedError()

NotImplementedError:
```

In [ ]:
```
# Deberia poder ver dos checkmarks verdes [0 marks], que indican que su informa

with tick.marks(0):
    assert(len(carne_1)>=5 and len(carne_2)>=5)

with tick.marks(0):
    assert(len(firma_mecanografiada_1)>0 and len(firma_mecanografiada_2)>0)
```

✓ [0 marks]

✓ [0 marks]

Dataset a Utilizar

Para este laboratorio seguriemos usando el dataset de Kaggle llamado Cats and Dogs image classification. Por favor, descarguenlo y ponganlo en una carpeta/folder de su computadora local.

Parte 1 - Construyendo una Red Neuronal Convolucional

Créditos: La primera parte de este laboratorio está tomado y basado en uno de los laboratorios dados dentro del curso de "Convolutional Neural Networks" de Andrew Ng

Muchos framework en la actualidad hacen que las operaciones de convolución sean fáciles de usar, pero no muchos entienden realmente este concepto, que es uno de los más interesantes de entender en Deep Learning. Una capa convolucional transforma el volumen de un input a un volumen de un output que es de un tamaño diferente.

En esta sección, ustedes implementaran una capa convolucional paso a paso. Primero empezaremos por hacer unas funciones de padding con ceros y luego otra para computar la convolución.

Algo muy importante a **notar** es que para cada función *forward*, hay una equivalente en *backward*. Por ello, en cada paso de su modulo de forward, deberán guardar algunos datos que se usarán durante el cálculo de gradientes en el backpropagation

Ejercicio 1

Ahora construiremos una función que se encargue de hacer *padding*, que como vimos en la clase es hacer un tipo de marco sobre la imagen. Este "marco" suele ser de diferentes tipos que lo que debe buscarse es que no tengan significacia dentro de la imagen, usualmente es cero, pero puede ser otro valor que no afecte en los cálculos.

Para este laboratorio, usaremos cero, y en este caso se le suele llamar *zero-padding* el cual agrega ceros alrededor del borde de la imagen.

Algo interesante a notar, es que este borde se agrega sobre cada uno de los canales de color de la imagen. Es decir, en una imagen RGB se agregará sobre la matriz de rojos, otro sobre la matriz de verdes y otro más sobre la matriz de azules.

Como se puede ver en la siguiente imagen.

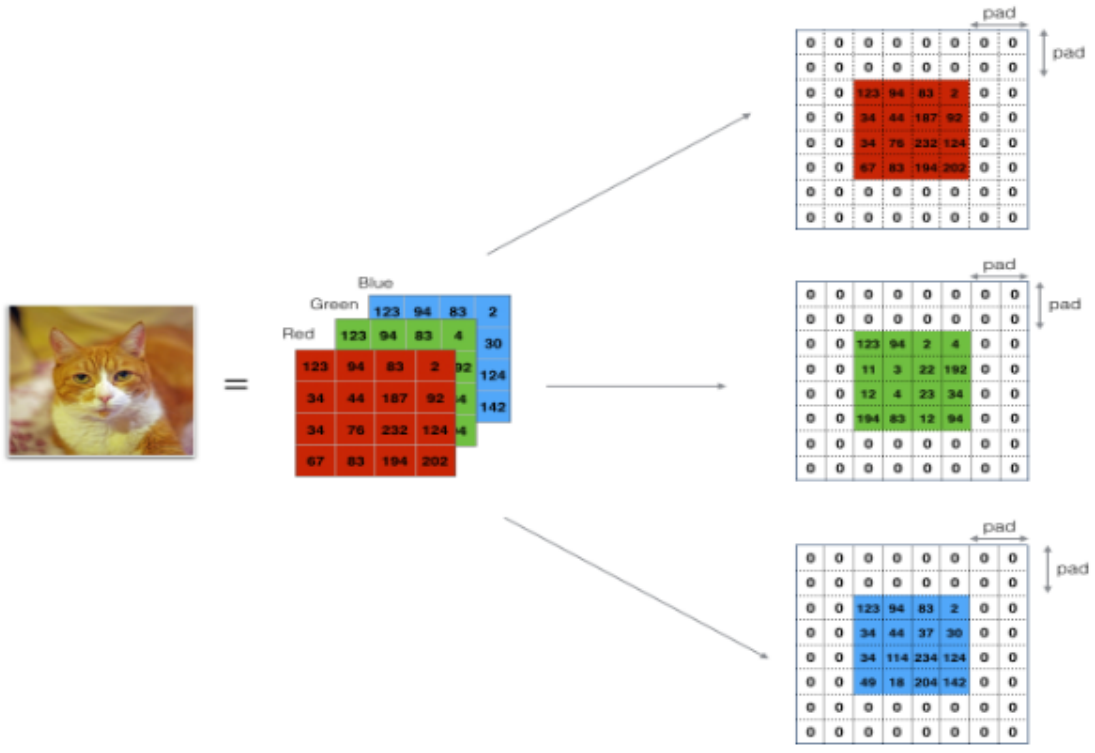

Crédito de imagen al autor, imagen tomada del curso "Convolutional Neural Networks" de Andrew Ng

Recordemos que el agregar padding nos permite:

- Usar una capa convolucional sin necesariamente reducir el alto y ancho de los volumenes de entrada. Esto es importante para cuando se crean modelos/redes profundas, dado que de esta manera evitamos reducir demasiado la entrada mientras se avanza en profunidad.
- Ayuda a obtener más información de los bordes de la imagen. Sin el padding, muy pocos valores serán afectados en la siguiente capa por los pixeles de las orillas

Ahora sí, el **ejercicio** como tal:

Implemente la siguiente función, la cual agregará el padding de ceros a todas las imagenes de un grupo (batch) de tamaño X. Para eso se usará *np.pad*.

Nota: Si se quiere agregar padding a un array "a" de tamaño (5,5,5,5,5) con un padding de tamaño diferente para cada dimensión, es decir, pad=1 para la segunda dimensión, pad=3 para la cuarta dimensión, y pad=0 para el resto, esto se puede hacer de la siguiente manera

`a = np.pad(a, ((0,0), (1,1), (0,0), (3,3), (0,0)), mode='constant', constant_values = (0,0))`

In [ ]:
```
import numpy as np

def zero_pad(X, pad):
    """
    Agrega padding de ceros a todas las imagenes en el dataset X. El padding es
    como se mostró en la figura anterior.

    Argument:
    X: Array (m, n_H, n_W, n_C) representando el batch de imagens
    pad: int, cantidad de padding

    Returns:
    X_pad: Imagen con padding agregado, (m, n_H + 2*pad, n_W + 2*pad, n_C)
    """

    # Aprox 1 línea de código
    # X_pad =
    # YOUR CODE HERE
    X_pad = np.pad(X, ((0,0), (pad,pad), (pad,pad), (0,0)), mode='constant', co

    #raise NotImplementedError()

    return X_pad
```

In [ ]:
```
np.random.seed(seed_)
x = np.random.randn(4, 3, 3, 2)
x_pad = zero_pad(x, 2)

print ("x.shape =\n", x.shape)
print ("x_pad.shape =\n", x_pad.shape)
print ("x[1,1] =\n", x[1,1])
print ("x_pad[1,1] =\n", x_pad[1,1])

# Mostrar imagen
```

```
fig, axarr = plt.subplots(1, 2)
axarr[0].set_title('x')
axarr[0].imshow(x[0,:,:,0])
axarr[1].set_title('x_pad')
axarr[1].imshow(x_pad[0,:,:,0])


with tick.marks(5):
    assert(check_hash(x_pad, ((4, 7, 7, 2), -1274.231087426035)))
```

```
x.shape =
 (4, 3, 3, 2)
x_pad.shape =
 (4, 7, 7, 2)
x[1,1] =
 [[ 0.64212494 -0.18117553]
 [ 0.77174916  0.74152348]
 [ 1.32476273  0.43928671]]
x_pad[1,1] =
 [[0. 0.]
 [0. 0.]
 [0. 0.]
 [0. 0.]
 [0. 0.]
 [0. 0.]
 [0. 0.]]
```

✓ [5 marks]

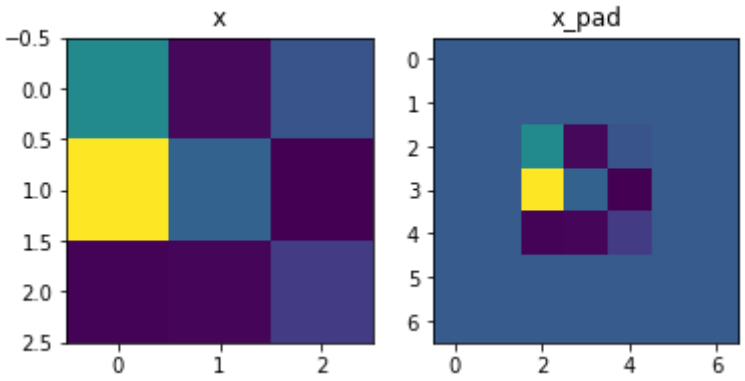

Ejercicio 2

Ahora, es momento de implementar un solo paso de la convolución, en esta ustedes aplicaran un filtro/kernel a una sola posición del input. Esta será usada para construir una unidad convolucional, la cual:

- Tomará una matriz (volumen) de input
- Aplicará un filtro a cada posición del input
- Sacará otra matriz (volumen) que será usualmente de diferente tamaño

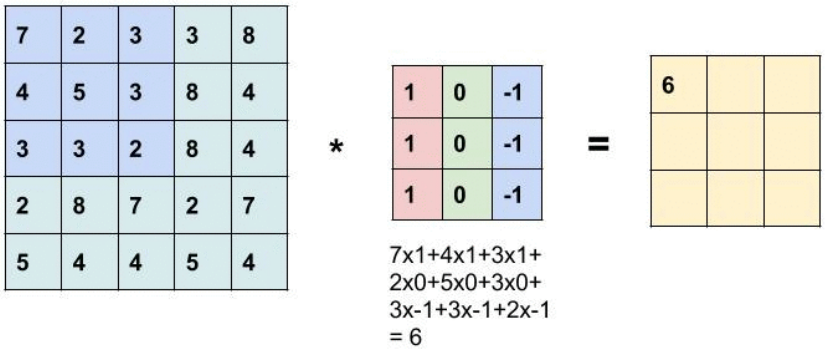

Crédito de la imagen al autor. Tomada de
https://medium.datadriveninvestor.com/convolutional-neural-networks-3b241a5da51e

En la anterior imagen, estamos viendo un filtro de 3x3 con un stride de 1 (recuerden que stride es la cantidad que se mueve la ventana). Además, lo que usualmente se hace con esta operación es una **multiplicación element-wise** (en clase les dije que era un producto punto, pero realmente es esta operación), para luego sumar la matriz y agregar un bias. Ahora, primero implementaran un solo paso de la convolución en el cual deberán aplicar un filtro a una sola posición y obtendrán un flotante como salida.

Ejercicio: Implemente la función conv_single_step()

Probablemente necesite esta función

Considre que la variable "b" será pasada como un numpy.array. Se se agrega un escalar (flotante o entero) a un np.array, el resultado será otro np.array. En el caso especial de cuando un np.array contiene un solo valor, se puede convertir a un flotante

In [ ]:
```
def conv_single_step(a_slice_prev, W, b):
    """
    Aplica un filtro definido en el parámetro W a un solo paso de
    slice (a_slice_prev) de la salida de activación de una capa previa

    Arguments:
    a_slice_prev: Slice shape (f, f, n_C_prev)
    W: Pesos contenidos en la ventana. Shape (f, f, n_C_prev)
    b: Bias contenidos en la ventana. Shape (1, 1, 1)

    Returns:
    Z: Un escalar, resultado de convolving la ventana (W, b)
    """

    # Aprox 2-3 lineas de codigo
```

```
    # Multiplicación element-wise
    # Z =
    # YOUR CODE HERE
    s = a_slice_prev * W
    Z = np.sum(s)
    Z = Z + np.squeeze(b)
    #raise NotImplementedError()

    return Z
```

In [ ]:
```
np.random.seed(seed_)
a_slice_prev = np.random.randn(4, 3, 3)
W = np.random.randn(4, 3, 3)
b = np.random.randn(1, 1, 1)
Z = conv_single_step(a_slice_prev, W, b)
print("Z =", Z)

with tick.marks(5):
    assert check_scalar(Z, '0x92594c5b')
```

```
Z = 17.154767154043057
```

✓ [5 marks]

Ejercicio 3

Ahora pasaremos a construir el paso de forward. En este, se tomará muchos filtros y los convolucionaran con los inputs. Cada "convolución" les dará como resultado una matriz 2D, las cuales se "stackearan" en una salida que será entonces de 3D.

Ejercicio: Implemente la función dada para convolucionar los filtros "W" con el input dado "A_prev". Esta función toma los siguientes inputs:

- A_prev, la salida de las activaciones de la capa previa (para un batch de m inputs)
- W, pesos. Cada uno tendra un tamaño de fxf
- b, bias, donde cada filtro tiene su propio bias (uno solo)
- hparameters, hiperparámetros como stride y padding

Considere lo siguiente: a. Para seleccionar una ventana (slice) de 2x2 en la esquina superior izquierda de una matriz a_prev, deberian hacer algo como `a_slice_prev = a_prev[0:2, 0:2, :]` Noten como esto da una salida 3D, debido a que tiene alto, ancho (de 2) y profundo (de 3 por los canales RGB). Esto le puede ser de utilidad cuando defina `a_slide_prev` en la función, usando los índices de `start/end`.

b. Oara definir `a_slice` necesitará primero definir las esquinas `vert_start`, `vert_end`, `horiz_start`, `horiz_end`. La imagen abajo puede resultar útil para entender como cada esquina puede ser definida usando h,w,f y s en el código.

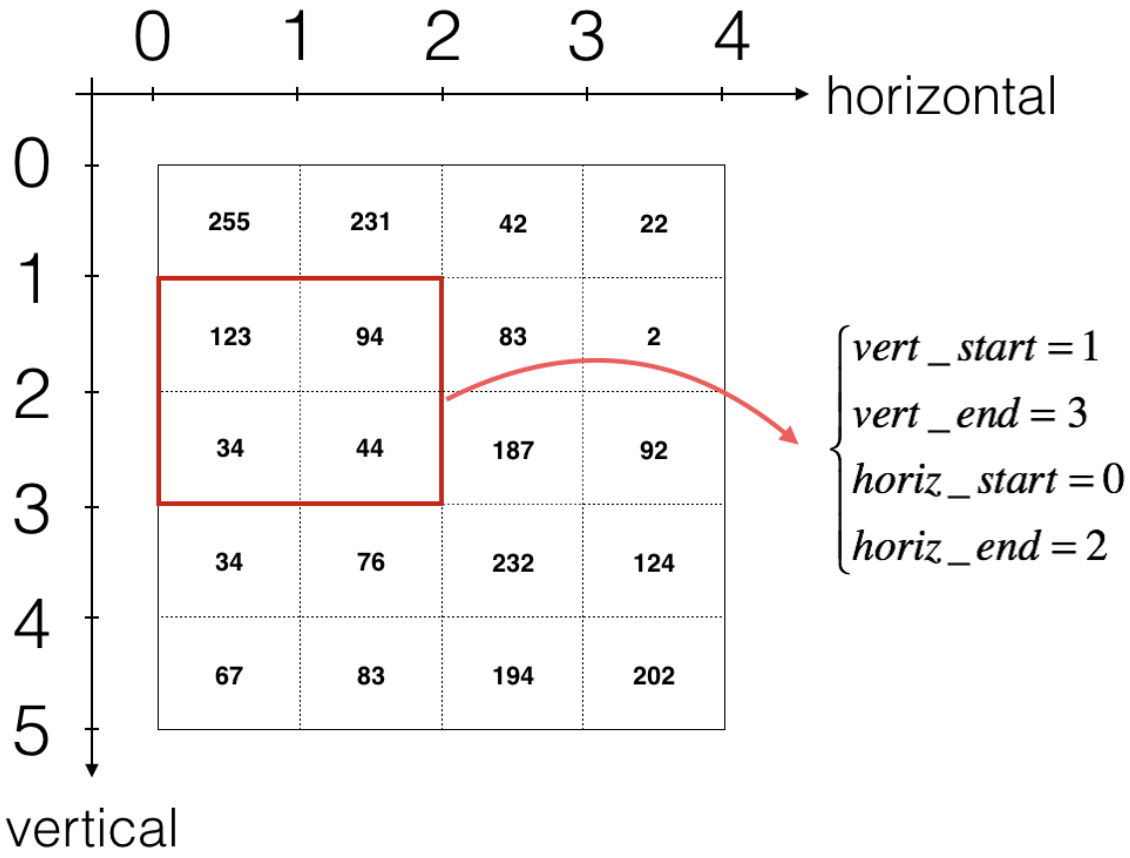

Crédito de imagen al autor, imagen tomada del curso "Convolutional Neural Networks" de Andrew Ng

Ahora, algo que debemos notar es que cada que hacemos una convolución con padding y stride, la salida de la operación será una matriz de diferente tamaño. Muchas veces necesitamos saber el tamaño de la matriz de modo que nos puede servir no solo para debuggear sino también para la misma definición de la arquitectura. La forma de generalizar esto es como sigue. Consideren una matriz de `nxn` que es convolucionada con un filtro de `fxf`, con un padding `p` y stride `s`, esto nos dará una matriz de `(n+2p-f)/s + 1` (Considere que en caso `(n+2p-f)/s + 1` sea una fracción, tomen el valor "piso".

Entonces, considere las siguientes formulas para saber la forma de la salida de una operación de convolución:

$$n_H = \lfloor \frac{n_{H_{prev}} - f + 2 \times pad}{stride} \rfloor + 1$$

$$n_W = \lfloor \frac{n_{W_{prev}} - f + 2 \times pad}{stride} \rfloor + 1$$

$$n_C = \text{número de filtros usados en la convolución}$$

Hints:

- Probablemente querán usar "slicing" (foo[0:2, :, 1:5]) para las variables `a_prev_pad`, `W`, `b`

- Para decidir como obtener `vert_start, vert_end, horiz_start, horiz_end`, recuerde que estos son índices de la capa previa
- Asegúrese de que `a_slice_prev` tiene alto, ancho y profunidad
- Recuerdo que `a_prev_pad` es un subconjunto de `A_prev_pad`

In [ ]:
```
def conv_forward(A_prev, W, b, hparameters):
    (m, n_H_prev, n_W_prev, n_C_prev) = A_prev.shape

    (f, f, n_C_prev, n_C) = W.shape

    stride = hparameters['stride']
    pad = hparameters['pad']
    n_H = int((n_H_prev - f + 2 * pad) / stride) + 1
    n_W = int((n_W_prev - f + 2 * pad) / stride) + 1
    Z = np.zeros((m, n_H, n_W, n_C))

    A_prev_pad = zero_pad(A_prev, pad)

    for i in range(m):
        a_prev_pad = A_prev_pad[i]
        for h in range(n_H):
            for w in range(n_W):
                for c in range(n_C):
                    vert_start = h * stride
                    vert_end = vert_start + f
                    horiz_start = w * stride
                    horiz_end = horiz_start + f

                    a_slice_prev = a_prev_pad[vert_start:vert_end, horiz_start:


                    weights = W[...,c]
                    biases = b[...,c]
                    Z[i, h, w, c] = conv_single_step(a_slice_prev, weights, bia


    assert(Z.shape == (m, n_H, n_W, n_C))


    cache = (A_prev, W, b, hparameters)

    return Z, cache
```

In [ ]:
```
np.random.seed(seed_)
A_prev = np.random.randn(10,7,7,5)
W = np.random.randn(3,3,5,8)
b = np.random.randn(1,1,1,8)
hparameters = {"pad" : 1,
               "stride": 1}

Z, cache_conv = conv_forward(A_prev, W, b, hparameters)
print("Z's mean =\n", np.mean(Z))
print("Z[3,2,1] =\n", Z[3,2,1])
print("cache_conv[0][1][2][3] =\n", cache_conv[0][1][2][3])

with tick.marks(5):
    assert check_hash(Z, ((10, 7, 7, 8), 2116728.6653762255))
```

```
with tick.marks(5):
    assert check_hash(cache_conv[0], ((10, 7, 7, 5), -12937.39104655015))

with tick.marks(5):
    assert check_scalar(np.mean(Z), '0xb416d11a')
```

```
Z's mean =
 0.3337664511415829
Z[3,2,1] =
 [ 4.1749337   9.00045401  1.79056239 -2.293963   -0.5189402  10.78547069
  1.42173371 13.11009042]
cache_conv[0][1][2][3] =
 [ 1.88596049  0.30974852 -0.3170466   0.481606   -0.43747686]
```

✓ [5 marks]

✓ [5 marks]

✓ [5 marks]

También deberíamos agregar una función de activación a la salida de la forma, que teniendo al salida Z

`Z[i, h, w, c] = ...`

Deberiamos aplicar la activación de forma que:

`A[i, h, w, c] = activation(Z[i, h, w, c])`

Pero esto no lo haremos acá

Ejercicio 4

Ahora lo que necesitamos es realizar la parte de "Pooling", la cual reducirá el alto y ancho del input. Este ayudará a reducir la complejidad computacional, así como también ayudará a detectar features más invariantes en su posición del input. Recuerden que hay dos tipos más comunes de pooling.

- Max-pooling: Mueve una ventana de (fxf) sobre un input y guarda el valor máximo de cada ventana en su salida
- Average-pooling: Mueve una ventana de (fxf) sobre un input y guarda el valor promedio de cada ventana en su salida

Estas capas de pooling no tienen parámetros para la parte de backpropagation al entrenar. Pero, estas tienen hiperparámetros como el tamaño de la ventana (f). Este especifica el alto y ancho de la ventana.

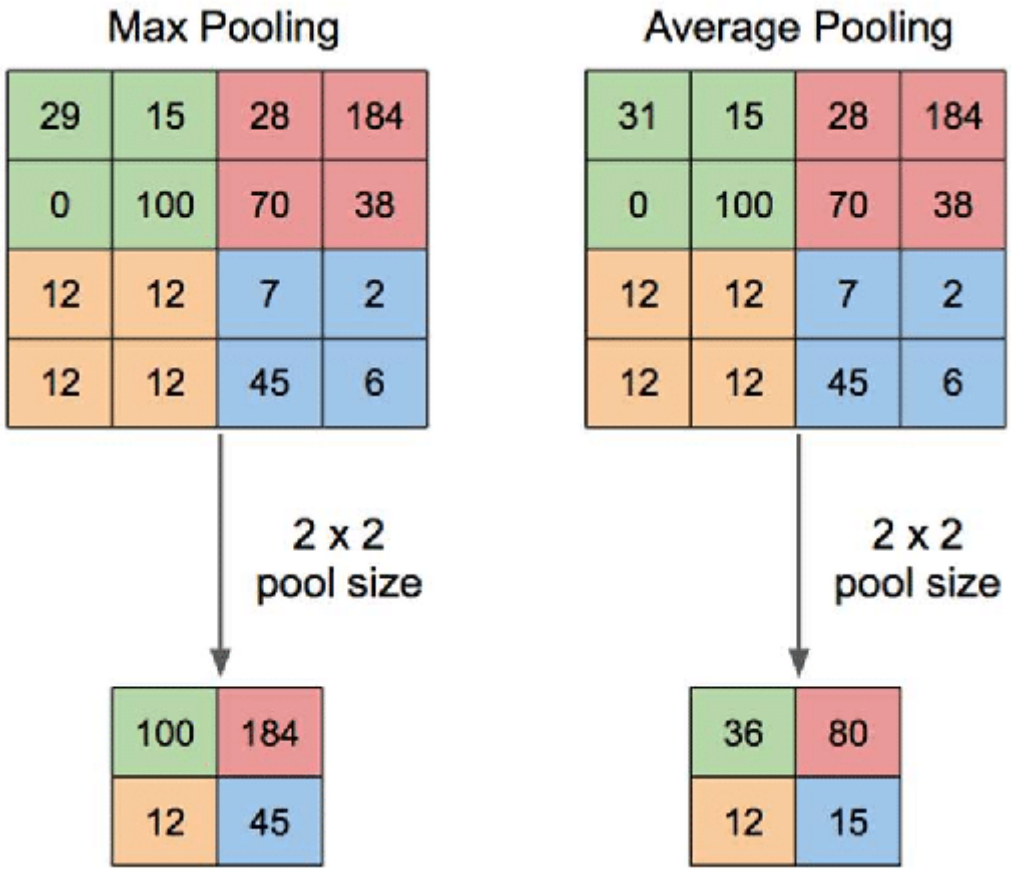

Crédito de imagen al autor, imagen tomada de[*https://www.researchgate.net/figure/Illustration-of-Max-Pooling-and-Average-Pooling-Figure-2-above-shows-an-example-of-max_fig2_333593451*](https://www.researchgate.net/figure/Illustration-of-Max-Pooling-and-Average-Pooling-Figure-2-above-shows-an-example-of-max_fig2_333593451)

Ejercicio: Implemente la función del paso forwarding de la capa de la capa de pooling.

Considere que como no hay padding, las formulas para los tamaños del output son:

$$n_H = \lfloor \frac{n_{H_{prev}} - f}{stride} \rfloor + 1$$

$$n_W = \lfloor \frac{n_{W_{prev}} - f}{stride} \rfloor + 1$$

$$n_C = n_{C_{prev}}$$

In [ ]:
```
def pool_forward(A_prev, hparameters, mode = "max"):
    (m, n_H_prev, n_W_prev, n_C_prev) = A_prev.shape

    f = hparameters["f"]
    stride = hparameters["stride"]

    n_H = int(1 + (n_H_prev - f) / stride)
    n_W = int(1 + (n_W_prev - f) / stride)
```

```
    n_C = n_C_prev

    A = np.zeros((m, n_H, n_W, n_C))

    for i in range(m):
        for h in range(n_H):
            vert_start = h * stride
            vert_end = vert_start + f
            for w in range(n_W):
                horiz_start = w * stride
                horiz_end = horiz_start + f
                for c in range(n_C):

                    a_prev_slice = A_prev[i, vert_start:vert_end, horiz_start:h

                    if mode == "max":
                        A[i, h, w, c] = np.max(a_prev_slice)
                    elif mode == "average":
                        A[i, h, w, c] = np.mean(a_prev_slice)

    cache = (A_prev, hparameters)

    assert(A.shape == (m, n_H, n_W, n_C))

    return A, cache
```

In [ ]:

```
np.random.seed(seed_)
A_prev = np.random.randn(2, 5, 5, 3)
hparameters = {"stride" : 1, "f": 3}

A, cache = pool_forward(A_prev, hparameters)
with tick.marks(5):
    assert check_hash(A, ((2, 3, 3, 3), 2132.191781663462))
print("mode = max")
print("A.shape = " + str(A.shape))
print("A =\n", A)
print()
A, cache = pool_forward(A_prev, hparameters, mode = "average")
with tick.marks(5):
    assert check_hash(A, ((2, 3, 3, 3), -14.942132313028413))
print("mode = average")
print("A.shape = " + str(A.shape))
print("A =\n", A)
```

✓ [5 marks]

```
mode = max
A.shape = (2, 3, 3, 3)
A =
 [[[[2.65440726 2.09732919 0.89256196]
    [2.65440726 2.09732919 0.89256196]
    [2.65440726 1.44060519 0.77174916]]

   [[1.5964877  2.39887598 0.89256196]
    [1.5964877  2.39887598 0.89256196]
    [1.5964877  2.39887598 0.77174916]]

   [[1.5964877  2.39887598 1.23583026]
    [1.5964877  2.39887598 1.36481958]
    [1.5964877  2.39887598 1.36481958]]]


  [[[1.84392163 2.43182155 1.29498747]
    [1.84392163 1.84444871 1.29498747]
    [0.6411132  1.84444871 1.16961103]]

   [[1.05650003 1.83680466 1.29498747]
    [1.05650003 0.9194503  1.29498747]
    [1.60523445 0.9194503  1.16961103]]

   [[1.06265456 1.83680466 0.68596995]
    [1.84881089 0.9194503  0.91014646]
    [1.84881089 1.42664748 1.06769765]]]]
```

✓ [5 marks]

```
mode = average
A.shape = (2, 3, 3, 3)
A =
 [[[[-0.03144582  0.21101766 -0.4691968 ]
    [-0.19309428  0.11749016 -0.32066469]
    [ 0.03682201  0.07413032 -0.36460992]]

   [[-0.58916194  0.45332745 -0.92209295]
    [ 0.01933338  0.23001555 -0.80282417]
    [ 0.33096648 -0.05773358 -0.55515521]]

   [[-0.19306801  0.61727733 -0.75579122]
    [ 0.34757347  0.47452468 -0.55854075]
    [ 0.52805193 -0.10908417 -0.5041339 ]]]


  [[[ 0.41867593  0.27110615  0.24018433]
    [-0.08325311  0.13111052  0.36317349]
    [-0.35974293 -0.13195187  0.30872263]]

   [[ 0.13066225  0.09595298 -0.31301579]
    [-0.36030628 -0.08070726  0.1281678 ]
    [-0.190839   -0.07153563  0.25708761]]

   [[ 0.11435948  0.17765852 -0.54259002]
    [ 0.17261558 -0.07438603 -0.32846615]
    [ 0.14368759  0.21413355  0.1648492 ]]]]
```

¡Muy bien terminamos la parte del paso forward!

Ejercicio 5

Antes de empezar con el ejercicio 5, debemos clarificar unas cuantas cosas.

Por ello, es momento de pasar a hacer el paso de backward propagation. En la mayoría de frameworks/librerías de la actualidad, solo deben implementarse el paso forward, y estas librerías se encargan de hacer el paso de backward. El backward puede ser complicado para una CNN.

Durante la semana pasada implementamos el backpropagation de una Fully Connected para calcular las derivadas con respecto de un costo. De similar manera, en CNN se debe calcular la derivada con respecto del costo para actualizar parámetros. Las ecuaciones de backpropagation no son triviales, por ello trataremos de entenderlas mejor acá

Calculando dA

Esta es la formula para calcular dA con respecto de costo para un filtro dado W_c y un ejemplo de entrenamiento dado

$$dA+ = \sum_{h=0}^{n_H} \sum_{w=0}^{n_W} W_c \times dZ_{hw} \tag{1}$$

Donde W_c es un filtro y dZ_{hw} es un escalar correspondiente a la gradiente del costo con respecto de la salida de la capa convolucional Z en la h-th fila y la w-th columna (correspondiente al producto punto tomado de la i-th stride en la izquierda y el j-th stride inferior). Noten que cada vez que multiplicamos el mismo filtro W_c por una dZ difrente cuando se actualiza dA. Esto lo hacemos principalmente cuando calculamos el paso forward, cada filtro es multiplicado (punto) y sumado por un differente a_slice. Entonces cuando calculamos el backpropagation para dA, estamos agregando todas las gradientes de a_slices.

En código, dentro del ciclo-for apropiado, esta formula se transforma en:

```
da_prev_pad[vert_start:vert_end, horiz_start:horiz_end, :] += W[:,:,:,c] * dZ[i, h, w, c]
```

Calculando dW

Esta es la formula para calcular dW_c (dW_c es la derivada de un solo filtro) con respecto de la perdida

$$dW_c+ = \sum_{h=0}^{n_H} \sum_{w=0}^{n_W} a_{slice} \times dZ_{hw} \tag{2}$$

Donde a*{slice} corresponde al slice que se usó para generar la activación de $dZ*{ij}*
$. Entonces, esto termina dando los la gradiente de W con respecto de ese eslice (ventana)$
. Debido a que el mismo$

W, $soloagregamostodaslasgradientesparaobtenerdW$

En código, dentro del ciclo-for apropiado, esta formula se transforma en:

`dW[:,:,:,c] += a_slice * dZ[i, h, w, c]`

Calculando db

Esta es la formula para calcular db con respecto del costo para un filtro dado Wc

$$db = \sum_h \sum_w dZ_{hw} \tag{3}$$

Como hemos previamente visto en una red neuronal básica, db es calculada al sumar dZ. En este caso, solo sumaremos sobre todas las gradientes de la salida conv (Z) con respecto del costo.

En código, dentro del ciclo-for apropiado, esta formula se transforma en:

`db[:,:,:,c] += dZ[i, h, w, c]`

Después de este preambulo, ahora pasemos al **ejercicio**. Deberá implementar la función `conv_backward`. Deberá sumar sobre todos los datos de entrenamiento, filtros, altos, y anchos. Luego, deberá calcular las derivadas usando las formulas 1-3, de arriba.

In [ ]:
```
def conv_backward(dZ, cache):
    (A_prev, W, b, hparameters) = cache

    (m, n_H_prev, n_W_prev, n_C_prev) = A_prev.shape

    (f, f, n_C_prev, n_C) = W.shape

    stride = hparameters["stride"]
    pad = hparameters["pad"]

    (m, n_H, n_W, n_C) = dZ.shape

    dA_prev = np.zeros((m, n_H_prev, n_W_prev, n_C_prev))
    dW = np.zeros((f, f, n_C_prev, n_C))
    db = np.zeros((1, 1, 1, n_C))

    A_prev_pad = zero_pad(A_prev, pad)
    dA_prev_pad = zero_pad(dA_prev, pad)

    for i in range(m):

        a_prev_pad = A_prev_pad[i]
        da_prev_pad = dA_prev_pad[i]

        for h in range(n_H):
            for w in range(n_W):
                for c in range(n_C):

                    vert_start = h * stride
                    vert_end = vert_start + f
                    horiz_start = w * stride
```

```
                    horiz_end = horiz_start + f

                    a_slice = a_prev_pad[vert_start:vert_end, horiz_start:horiz

                    da_prev_pad[vert_start:vert_end, horiz_start:horiz_end, :]
                    dW[:,:,:,c] += a_slice * dZ[i, h, w, c]
                    db[:,:,:,c] += dZ[i, h, w, c]

        dA_prev[i, :, :, :] = da_prev_pad[pad:-pad, pad:-pad, :]

    assert(dA_prev.shape == (m, n_H_prev, n_W_prev, n_C_prev))

    return dA_prev, dW, db
```

In [ ]:
```
np.random.seed(seed_)

dA, dW, db = conv_backward(Z, cache_conv)
print("dA_mean =", np.mean(dA))
print("dW_mean =", np.mean(dW))
print("db_mean =", np.mean(db))

with tick.marks(5):
    assert(check_hash(dA, ((10, 7, 7, 5), 5720525.244018247)))

with tick.marks(5):
    assert(check_hash(dW, ((3, 3, 5, 8), -2261214.2801842494)))

with tick.marks(5):
    assert(check_hash(db, ((1, 1, 1, 8), 11211.666220998337)))
```

```
dA_mean = 1.7587047105903002
dW_mean = -30.84696464944313
db_mean = 163.5455610593757
```

✓ [5 marks]

✓ [5 marks]

✓ [5 marks]

Ejercicio 6

Es momento de hacer el paso backward para la **capa pooling**. Vamos a empezar con la versión max-pooling. Noten que incluso aunque las capas de pooling no tienen parámetros para actualizar en backpropagation, aun se necesita pasar el gradiente en backpropagation por las capas de pooling para calcular los gradientes de las capas que vinieron antes de la capa de pooling

Max-pooling paso Backward

Antes de ir al backpropagation de la capa de pooling, vamos a crear una función de apoyo llamada `create_mask_from_window()` que hará lo siguiente

$$X = \begin{bmatrix} 1 & 3 \\ 4 & 2 \end{bmatrix} \quad \rightarrow \quad M = \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix} \tag{4}$$

Como pueden observar, esta función creará una matriz "máscara" que ayudará a llevar tracking de donde está el valor máximo. El valor 1 indica la posición del máximo de una matriz X, las demás posiciones son 0. Veremos más adelante que el paso backward con average-pooling es similar pero con diferente máscara

Ejercicio: Implemente la función `create_mask_from_window()` .

Hints:

- np.max() puede ser de ayuda.
- Si tienen una matriz X y un escalar x: `A = (X==x)` devolverá una matriz A del mismo tamaño de X tal que:

`A[i,j] = True if X[i,j] = x`

`A[i,j] = False if X[i,j] != x`

- En este caso, no considere casos donde hay varios máximos en una matriz

In [ ]:
```
def create_mask_from_window(x):

    mask = (x == np.max(x))

    return mask
```

In [ ]:
```
np.random.seed(seed_)
x = np.random.randn(2,3)
mask = create_mask_from_window(x)
print('x = ', x)
print("mask = ", mask)

with tick.marks(5):
    assert(check_hash(mask, ((2, 3), 2.5393446629166316)))
```

```
x =  [[ 0.71167353 -0.32448496 -1.00187064]
 [ 0.23625079 -0.10215984 -1.14129263]]
mask =  [[ True False False]
 [False False False]]
```

✓ [5 marks]

Es válido preguntarse ¿por qué hacemos un seguimiento de la posición del máximo? Es porque este es el valor de entrada que finalmente influyó en la salida y, por lo tanto, en el costo.

Backprop está calculando gradientes con respecto al costo, por lo que todo lo que influya en el costo final debe tener un gradiente distinto de cero. Entonces, backprop "propagará" el gradiente de regreso a este valor de entrada particular que influyó en el costo.

Average-pooling paso Backward

En max-pooling, para cada ventana de entrada, toda la "influencia" en la salida provino de un solo valor de entrada: el máximo. En la agrupación promedio, cada elemento de la ventana de entrada tiene la misma influencia en la salida. Entonces, para implementar backprop, ahora implementaramos una función auxiliar que refleje esto.

$$dZ = 1 \quad \rightarrow \quad dZ = \begin{bmatrix} 1/4 & 1/4 \\ 1/4 & 1/4 \end{bmatrix} \tag{5}$$

Esto implica que cada posición en la matriz contribuye por igual a la salida porque en el pase hacia adelante tomamos un promedio.

Ejercicio: Implemente la función para distribuir de igual manera el valor dz en una matriz del mismo tamaño de "shape"

In [ ]:
```
def distribute_value(dz, shape):
    """
    Distribuye la entrada en una matriz de la misma dimensión de shape

    Arguments:
    dz: Input
    shape: La forma (n_H, n_W) de la salida

    Returns:
    a: Array, shape (n_H, n_W)
    """

    # Aprox 3 lieneas para
    # (n_H, n_W) =
    # average =
    # a =
    # YOUR CODE HERE
    (n_H, n_W) = shape

    average = dz / (n_H * n_W)

    a = np.ones(shape) * average

    return a
```

In [ ]:
```
a = distribute_value(5, (7,7))
print('valor distribuido =', a)
```

```
with tick.marks(5):
    assert check_scalar(a[0][0], '0x23121715')
```

```
valor distribuido = [[0.10204082 0.10204082 0.10204082 0.10204082 0.10204082
0.10204082
  0.10204082]
 [0.10204082 0.10204082 0.10204082 0.10204082 0.10204082 0.10204082
  0.10204082]
 [0.10204082 0.10204082 0.10204082 0.10204082 0.10204082 0.10204082
  0.10204082]
 [0.10204082 0.10204082 0.10204082 0.10204082 0.10204082 0.10204082
  0.10204082]
 [0.10204082 0.10204082 0.10204082 0.10204082 0.10204082 0.10204082
  0.10204082]
 [0.10204082 0.10204082 0.10204082 0.10204082 0.10204082 0.10204082
  0.10204082]
 [0.10204082 0.10204082 0.10204082 0.10204082 0.10204082 0.10204082
  0.10204082]]
```

✓ [5 marks]

Ejercicio 7

Ahora tienen todo lo necesario para calcular el backpropagation en una capa de agrupación.

Ejercicio: Implementen la función `pool_backward` en ambos modos ("max" y "average"). Una vez más, usarán 4 loops-for (iterando sobre ejemplos de entrenamiento, altura, ancho y canales). Debe usar una instrucción `if/elif` para ver si el modo es igual a 'máximo' o 'promedio'. Si es igual a 'promedio', debe usar la función `distribuir_valor ()` que se creo anteriormente para crear una matriz de la misma forma que "a_slice". De lo contrario, el modo es igual a 'max', y creará una máscara con `create_mask_from_window()` y la multiplicará por el valor correspondiente de `dZ`.

In [ ]:
```
def pool_backward(dA, cache, mode = "max"):
    """
    Implements the backward pass of the pooling layer

    Arguments:
    dA -- gradient of cost with respect to the output of the pooling layer, sam
    cache -- cache output from the forward pass of the pooling layer, contains
    mode -- the pooling mode you would like to use, defined as a string ("max"

    Returns:
    dA_prev -- gradient of cost with respect to the input of the pooling layer,
    """


    (A_prev, hparameters) = cache

    stride = hparameters["stride"]
    f = hparameters["f"]

    m, n_H_prev, n_W_prev, n_C_prev = A_prev.shape
```

```
    m, n_H, n_W, n_C = dA.shape

    dA_prev = np.zeros(A_prev.shape)

    for i in range(m):
        a_prev = A_prev[i]

        for h in range(n_H):
            for w in range(n_W):
                for c in range(n_C):

                    vert_start = h * stride
                    vert_end = vert_start + f
                    horiz_start = w * stride
                    horiz_end = horiz_start + f

                    if mode == "max":
                        a_prev_slice = a_prev[vert_start:vert_end, horiz_start:

                        mask = create_mask_from_window(a_prev_slice)
                        dA_prev[i, vert_start:vert_end, horiz_start:horiz_end,

                    elif mode == "average":
                        da = dA[i, h, w, c]
                        shape = (f, f)
                        dA_prev[i, vert_start:vert_end, horiz_start:horiz_end,

    assert(dA_prev.shape == A_prev.shape)

    return dA_prev
```

In [ ]:

```
np.random.seed(seed_)
A_prev = np.random.randn(5, 5, 3, 2)
hparameters = {"stride" : 1, "f": 2}
A, cache = pool_forward(A_prev, hparameters)
print(A.shape)
dA = np.random.randn(5, 4, 2, 2)

dA_prev = pool_backward(dA, cache, mode = "max")
print("mode = max")
print('mean of dA = ', np.mean(dA))
print('dA_prev[1,1] = ', dA_prev[1,1])
print()
with tick.marks(5):
    assert(check_hash(dA_prev, ((5, 5, 3, 2), 1166.727871556145)))

dA_prev = pool_backward(dA, cache, mode = "average")
print("mode = average")
print('mean of dA = ', np.mean(dA))
print('dA_prev[1,1] = ', dA_prev[1,1])
with tick.marks(5):
    assert(check_hash(dA_prev, ((5, 5, 3, 2), 1131.4343089227643)))
```

```
(5, 4, 2, 2)
mode = max
mean of dA =  0.10390017715645054
dA_prev[1,1] =  [[ 1.24312631  0.        ]
 [ 0.         -1.05329248]
 [-1.03592891  0.        ]]
```

✓ [5 marks]

```
mode = average
mean of dA =  0.10390017715645054
dA_prev[1,1] =  [[ 0.31078158  0.10580814]
 [ 0.30923847 -0.2046901 ]
 [-0.00154311 -0.31049824]]
```

✓ [5 marks]

Ejercicio 8

Hemos hecho todas las partes "a mano", es momento entonces de unir todo para intentar predecir nuevamente gatitos y perritos.

Tengan en cuenta que volveremos a usar el mismo método de la última vez pero ahora bajaremos significativamente la resolución de las imagenes para agilizar el proceso de entrenamiento. Esto, logicamente, afectará al resultado final, pero no se preocupen, está bien si les sale una pérdida excesivamente alta y un accuracy demasiado bajo, lo importante de este paso es que entiendan como todo se entrelaza. Además, muchas de las funciones para terminar de enlanzar todo les son dadas, no está de más que las lean y entiendan que sucede, pero ustedes deberán implementar varias también.

Para esta parte esparemos haciendo una arquitectura bastante simple, siendo esta algo como sigue

Input (64x64x3) --> Conv Layer (16 filters, 3x3, stride 1) --> ReLU Activation --> Max Pooling (2x2, stride 2) --> Fully Connected Layer (2 classes) --> Softmax Activation --> Output (Probs para Gato y Perro)

Se podría visualizar de una forma como la que se muestra en la siguiente imagen

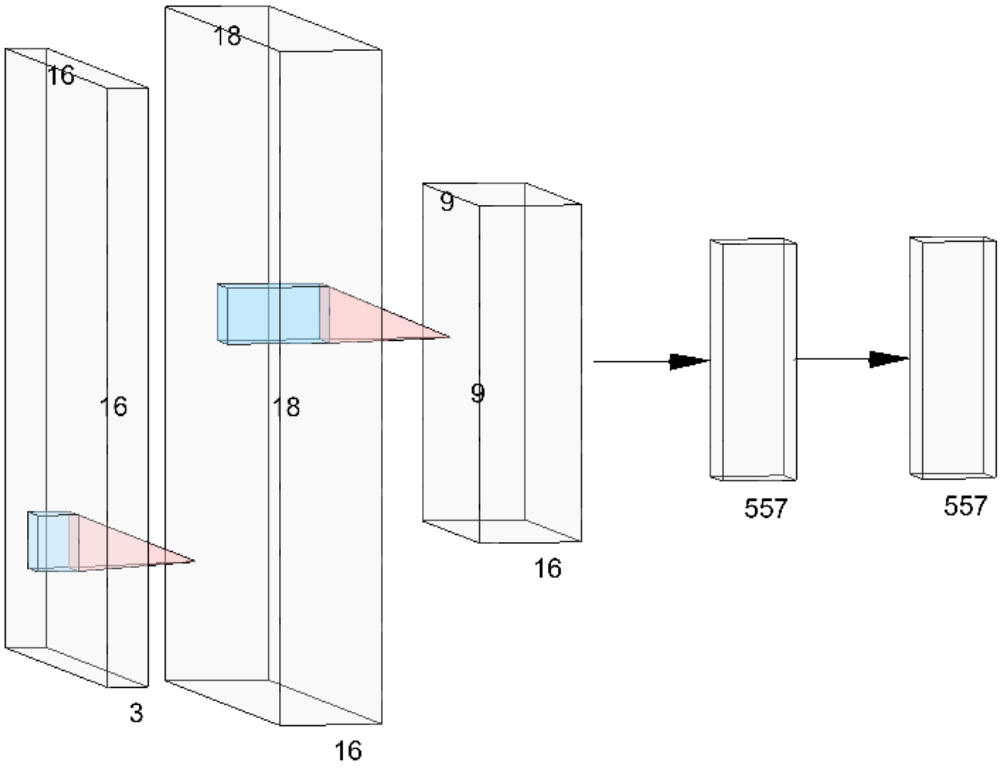

(Si en algun momento necesitan crear visualizaciones de arquitecturas de DL pueden usar la pagina https://alexlenail.me/NN-SVG/AlexNet.html)

Ejercicio: Implementen la función `simple_cnn_model`, la cual se encargará de formar el forward pass, luego implemente la función `backward_propagation`, que se encargará de hacer el backward propagation y calculo de gradientes. Finalmente, implemente `update_parameters` que deberá actualziar los filtros y biases.

In [ ]:
```
# Por favor cambien esta ruta a la que corresponda en sus maquinas
data_dir = "./archive/"

train_images = []
train_labels = []
test_images = []
test_labels = []

def read_images(folder_path, label, target_size, color_mode='RGB'):
    for filename in os.listdir(folder_path):
        image_path = os.path.join(folder_path, filename)
        # Use PIL to open the image
        image = Image.open(image_path)

        # Convert to a specific color mode (e.g., 'RGB' or 'L' for grayscale)
        image = image.convert(color_mode)

        # Resize the image to the target size
        image = image.resize(target_size)
```

```
        # Convert the image to a numpy array and add it to the appropriate list
        if label == "cats":
            if 'train' in folder_path:
                train_images.append(np.array(image))
                train_labels.append(0)  # Assuming 0 represents cats
            else:
                test_images.append(np.array(image))
                test_labels.append(0)  # Assuming 0 represents cats
        elif label == "dogs":
            if 'train' in folder_path:
                train_images.append(np.array(image))
                train_labels.append(1)  # Assuming 1 represents dogs
            else:
                test_images.append(np.array(image))
                test_labels.append(1)  # Assuming 1 represents dogs
# Call the function for both the 'train' and 'test' folders
train_cats_path = os.path.join(data_dir, 'train', 'cats')
train_dogs_path = os.path.join(data_dir, 'train', 'dogs')
test_cats_path = os.path.join(data_dir, 'test', 'cats')
test_dogs_path = os.path.join(data_dir, 'test', 'dogs')


# Read images
target_size = (16, 16)
read_images(train_cats_path, "cats", target_size)
read_images(train_dogs_path, "dogs", target_size)
read_images(test_cats_path, "cats", target_size)
read_images(test_dogs_path, "dogs", target_size)

# Convert the lists to numpy arrays
train_images = np.array(train_images)
train_labels = np.array(train_labels)
test_images = np.array(test_images)
test_labels = np.array(test_labels)

# Reshape the labels
train_labels = train_labels.reshape((1, len(train_labels)))
test_labels = test_labels.reshape((1, len(test_labels)))
```

In [ ]:

```
# Ejemplo de una imagen
# Sí, ahora se ve menos el pobre gatito :(
index = 25
plt.imshow(train_images[index])
print ("y = " + str(train_labels[0][index]) + ", es una imagen de un " + 'gato'
```

```
y = 0, es una imagen de un gato
```

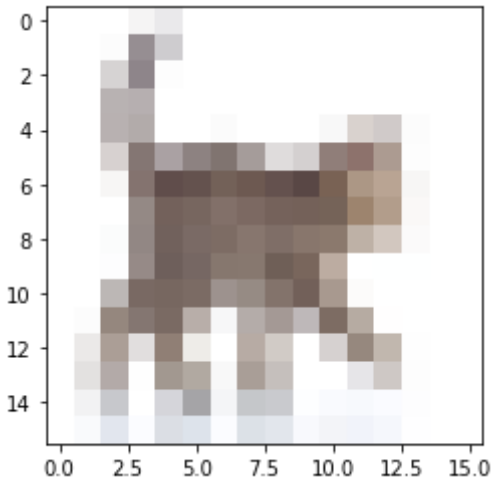

In [ ]:
```
np.random.seed(seed_)

def one_hot_encode(labels, num_classes):
    """
    Convierte labels categoricos a vectores

    Arguments:
    labels: Array shape (m,)
    num_classes: Número de clases

    Returns:
    one_hot: Array, shape (m, num_classes)
    """
    m = labels.shape[0]
    one_hot = np.zeros((m, num_classes))
    one_hot[np.arange(m), labels] = 1
    return one_hot


def relu(Z):
    """
    Aplica ReLU como funcion de activación al input

    Arguments:
    Z: Input

    Returns:
    A: Output array, mismo shape de Z
    cache: Contiena a Z para usar en el backprop
    """
    A = np.maximum(0, Z)
    cache = Z
    return A, cache


def relu_backward(dA, cache):
    """
    Calcula la derivada del costo con respecto del input de ReLU

    Arguments:
    dA: Gradiente del costo con respecto del output de ReLU
    cache: Z del paso forward
```

```
    Returns:
    dZ: Gradiente del costo con respecto del input
    """
    Z = cache
    dZ = np.multiply(dA, Z > 0)
    return dZ


def softmax(Z):
    """
    Aplica softmax al input

    Arguments:
    Z: Input array, shape (m, C), m = # de ejemplso, C = # de clases

    Returns:
    A : Salida con softmax
    """
    e_Z = np.exp(Z - np.max(Z, axis=1, keepdims=True))
    A = e_Z / np.sum(e_Z, axis=1, keepdims=True)
    return A


def softmax_backward(A):
    """
    Calcula la derivada de softmax

    Arguments:
    A: Salida del softmax

    Returns:
    dA: Gradiente del costo con respecto de la salida del softmax
    """
    dA = A * (1 - A)
    return dA

def initialize_parameters(n_H, n_W, n_C):
    """
    Inicializa los parametros de la CNN

    Arguments:
    n_H: Alto de las imagenes
    n_W: Ancho de las imagenes
    n_C: Canales

    Returns:
    parameters: Diccionario con los filtros y biases
    """
    parameters = {}

    # First convolutional layer
    parameters['W1'] = np.random.randn(3, 3, n_C, 16) * 0.01
    parameters['b1'] = np.zeros((1, 1, 1, 16))

    # Second convolutional layer - Not used to much time on training
    #parameters['W2'] = np.random.randn(3, 3, 16, 32) * 0.01
    #parameters['b2'] = np.zeros((1, 1, 1, 32))

    # Fully connected layer
    parameters['W3'] = np.random.randn(1296, 2) * 0.01
```

```
    parameters['b3'] = np.zeros((1, 2))

    return parameters

def conv_layer_forward(A_prev, W, b, hparameters_conv):
    """
    Forward pass de una capa convolucional

    Arguments:
    A_prev: Matriz previa
    W: Filtro
    b: Biases
    hparameters_conv: hiperparametros

    Returns:
    A: Nueva matriz de datos
    cache: Cache con la info de ReLU y la convolucional
    """
    Z, cache_conv = conv_forward(A_prev, W, b, hparameters_conv)
    A, cache_relu = relu(Z)
    cache = (cache_conv, cache_relu)
    return A, cache

def pool_layer_forward(A_prev, hparameters_pool, mode='max'):
    """
    Llama a la función realizada previamente - Ver docstring de pool_forward
    """
    A, cache = pool_forward(A_prev, hparameters_pool, mode)
    return A, cache

def fully_connected_layer_forward(A2, A_prev_flatten, W, b):
    """
    Forward pass de fully connected

    Arguments:
    A2: Matriz previa no aplanada
    A_prev_flatten: Matriz previa aplanada
    W: Filtro
    b: Biases

    Returns:
    A: Nueva matriz de datos
    cache: Cache con la info de ReLU y la convolucional
    """
    Z = np.dot(A_prev_flatten, W) + b
    A = softmax(Z) # cache_fc = softmax(Z)
    cache = (A2, A_prev_flatten, W, b, Z, A)
    return A, cache
def simple_cnn_model(image_array, parameters):
    """
    Implementa un modelo simple de CNN para predeciri si una imagen es un perri

    Arguments:
    image_array: Imagenes, shape (m, n_H, n_W, n_C)
    parameters: Diccionario con los filtros y pesos de cada capa

    Returns:
    A_last: Salida de la ultima capa (Probabilidades softmax para ambas clases)
    caches: Lista de caches con lo necesario para backward prop
    """
```

```
    W1 = parameters['W1']
    b1 = parameters['b1']
    W3 = parameters['W3']
    b3 = parameters['b3']

    hparameters_conv = {"stride": 1, "pad": 2}
    hparameters_pool = {"f": 2, "stride": 2}

    A1, cache0 = conv_layer_forward(image_array, W1, b1, hparameters_conv)
    A2, cache1 = pool_layer_forward(A1, hparameters_pool, mode='max')

    A2_flatten = A2.reshape(A2.shape[0], -1)

    A_last, cache2 = fully_connected_layer_forward(A2, A2_flatten, W3, b3)

    caches = [cache0, cache1, cache2]

    return A_last, caches

def compute_cost(A_last, Y):
    """
    Calcula el costo de cross-entroy para las probabilidades predichas

    Arguments:
    A_last: Prob predichas, shape (m, 2)
    Y: Labels verdaders, shape (m, 2)

    Returns:
    cost: cross-entropy cost
    """
    m = Y.shape[0]
    cost = -1/m * np.sum(Y * np.log(A_last + 1e-8))
    return cost

def fully_connected_layer_backward(dA_last, cache, m):
    """
    Calcula el backward pass de la fully connected

    Arguments:
    dA_last: Matriz de valores
    cache: cache util
    m: Cantidad de obs

    Returns:
    dA_prev: Derivada de la matriz
    dW: Derivada del costo con respecto del filtro
    db: Derivada del costo con respecto de bias
    """
    A_prev_unflatten, A_prev_flatten, W, b, Z, A_last = cache
    dZ = dA_last * softmax_backward(A_last)
    dW = np.dot(A_prev_flatten.T, dZ) / m
    db = np.sum(dZ, axis=0, keepdims=True) / m
    dA_prev_flatten = np.dot(dZ, W.T)
    dA_prev = dA_prev_flatten.reshape(A_prev_flatten.shape)
    return dA_prev, dW, db

def pool_layer_backward(dA, cache, mode='max'):
    """
    Llama al metodo antes definido - Ver docstring de pool_backward
    """
```

```
    return pool_backward(dA, cache, mode)

def conv_layer_backward(dA, cache):
    """
    Llama al metodo antes definido - Ver docstring de conv_backward
    """
    dZ = relu_backward(dA, cache[1])
    dA_prev, dW, db = conv_backward(dZ, cache[0])
    return dA_prev, dW, db

def backward_propagation(A_last, Y, caches):
    """
    Implemente la parte de backward prop de nuestro modelo

    Arguments:
    A_last: Probabilidades predichas, shape (m, 2)
    Y: Labels verdaderas, shape (m, 2)
    caches: Lista de caches con info para el back prop

    Returns:
    gradients: Diccionario con gradientes de filtros y biases para cada capa
    """
    m = Y.shape[0]
    gradients = {}
    # Compute the derivative of the cost with respect to the softmax output
    dZ3 = A_last - Y

    # Aprox 1 linea para hacer backprog en la fully connected layer y guardarlo
    gradients['dA2_flatten'], gradients['dW3'], gradients['db3'] = fully_connec

    # Reshape dA2_flatten to match the shape of dA2
    dA2 = gradients['dA2_flatten'].reshape(caches[2][0].shape)

    # Backpropagation through the second convolutional layer and pooling layer
    # Aprox 2 lineas para hacer el backprop en la pooling y la convolucional y
    gradients['dA1_pool'] = pool_layer_backward(dA2, caches[1], mode='max')
    gradients['dA1'], gradients['dW1'], gradients['db1'] = conv_layer_backward(

    return gradients



def update_parameters(parameters, gradients, learning_rate=0.01):
    """
    Actualiza los filtros y biases usando gradiente descendiente

    Arguments:
    parameters: Diccionario con filtros y biases de cada layer
    gradients: Diccionario con gradientes de filtros y biases de cada layer
    learning_rate: learning rate para gradient descent (default: 0.01)

    Returns:
    parameters: Parametros actualizados despues de un paso en la grad descent
    """
    # Aprox 4 lineas para calculo de W1, b1, W3,b3 (si, no hay continuidad en l
    # parameters['W1'] -=
    # parameters['b1'] -=
    # parameters['W3'] -=
    # parameters['b3'] -=
    # YOUR CODE HERE
```

```
    parameters['W1'] -= learning_rate * gradients['dW1']
    parameters['b1'] -= learning_rate * gradients['db1']
    parameters['W3'] -= learning_rate * gradients['dW3']
    parameters['b3'] -= learning_rate * gradients['db3']

    return parameters
```

In [ ]:
```
np.random.seed(seed_)

# Initialize the parameters of the CNN model
parameters = initialize_parameters(n_H=target_size[0], n_W=target_size[1], n_C=

# Training loop
# Noten como estamos usando bien poquitas epocas, pero es para que no les tome
num_epochs = 5
learning_rate = 0.01
```

In [ ]:
```
np.random.seed(seed_)

# Combine the train_images and test_images into one array
X_train = train_images #np.concatenate((train_images, test_images), axis=0)

# Combine the train_labels and test_labels into one array
Y_train_labels = train_labels #np.concatenate((train_labels, test_labels), axis

# Convert labels to one-hot encoding
num_classes = 2
Y_train = one_hot_encode(Y_train_labels, num_classes)
```

In [ ]:
```
np.random.seed(seed_)

for epoch in range(num_epochs):
    # Forward propagation
    A_last, caches = simple_cnn_model(X_train, parameters)

    # Compute the cost
    cost = compute_cost(A_last, Y_train)

    # Backward propagation
    gradients = backward_propagation(A_last, Y_train, caches)

    # Update parameters using gradient descent
    parameters = update_parameters(parameters, gradients, learning_rate)

    # Print the cost every few epochs - Removed not used due high times
    #if epoch % 10 == 0:
    print(f"Epoch {epoch+1}, Cost: {cost}")

print("Training completed.")
```

```
Epoch 1, Cost: 2370.7655299381468
Epoch 2, Cost: 10260.319168811471
Epoch 3, Cost: 10260.319168811471
Epoch 4, Cost: 10260.319168811471
Epoch 5, Cost: 10260.319168811471
Training completed.
```

In [ ]:
```
with tick.marks(10):
    assert check_scalar(cost, '0xd574bb64')
```

✓ [10 marks]

In [ ]:
```
# Testing the model using the test dataset
def test_model(X_test, Y_test, parameters):
    """
    Testea el modelo CNN usando el dataset

    Arguments:
    X_test: Imagenes, shape (m, n_H, n_W, n_C)
    Y_test: Labels verdaders para probas las imagenes, shape (m, num_classes)
    parameters: Diccionario con filtros y biases de cada capa

    Returns:
    accuracy: Accuracy
    """
    # Forward propagation
    A_last, _ = simple_cnn_model(X_test, parameters)

    # Convert softmax output to predicted class labels (0 for cat, 1 for dog)
    predictions = np.argmax(A_last, axis=1)

    # Convert true labels to class labels
    true_labels = np.argmax(Y_test, axis=1)

    # Calculate accuracy
    accuracy = np.mean(predictions == true_labels) * 100
    return accuracy

# Test the model on the test dataset
accuracy = test_model(test_images, one_hot_encode(test_labels, 2), parameters)
print(f"Test Accuracy: {accuracy:.2f}%")
```

```
Test Accuracy: 0.00%
```

In [ ]:
```
with tick.marks(10):
    assert check_scalar(accuracy, '0x75c2e82a')
```

✓ [10 marks]

Entonces, como podemos ver el modelo creado es **realmente** malo. Pero para fines didácticos cumple con su cometido 😄

NOTA: Conteste como txt, pdf, comentario en la entrega o en este mismo notebook:

- ¿Por qué creen que es el mal rendimiento de este modelo?
- Es un modelo muy básico, por lo tanto puede ser que no sea lo suficientemente complejo para poder clasificar las imágenes.

- ¿Qué pueden hacer para mejorarlo?
- Verificar que no exista sobreajuste, ajustar los hiperparámetros del modelo. Así como también optimizarlo con un algoritmo de optimización como Adam, o también RMSProp.
- ¿Cuáles son las razones para que el modelo sea tan lento?
- Porque las implementaciones son hechas "a mano", en vez de usar PyTorch, por ejemplo. Así mismo, puede ser que el modelo no es para nada optimizado con el gradient descent. Por estos motivos, el modelo es lento.

Ahora pasemos a ver como hacer algo mejor para el mismo tipo de tarea usando PyTorch 😊

Parte 2 - Usando PyTorch

Muy bien, hemos entendido ahora de mejor manera todo lo que sucede dentro de una red neuronal convolucional. Pasamos desde definir los pasos de forward, hasta incursionar en cómo realizar los pasos de backpropagation y al final, vimos una forma simple pero academicamente efectiva para entender lo que sucede dentro de una CNN.

Ahora, subamos un nivel y pasemos a ver como PyTorch nos ayuda a crear una CNN básica pero efectiva. Pero antes, es necesario que definamos la unidad básica de PyTorch, esta es conocida como Tensor 🤔

Tensor

En PyTorch, un tensor es una estructura de datos fundamental que representa matrices multidimensionales o matrices n-dimensionales. Los tensores son similares a las matrices o arrays de NumPy, pero tienen características y funcionalidades adicionales que están optimizadas para tareas de Deep Learning, incluida la diferenciación automática para el cálculo de gradientes durante la retropropagación.

En PyTorch, se puede crear un tensor para representar datos numéricos, como imágenes, sonidos o cualquier otro dato numérico que pueda necesitar. Los tensores se pueden manipular mediante operaciones matemáticas como la suma, la resta y la multiplicación, lo que los hace esenciales para construir y entrenar modelos de Deep Learning.

Los tensores en PyTorch y los arrays de NumPy comparten similitudes y pueden realizar operaciones similares. Sin embargo, los tensores de PyTorch están diseñados específicamente para tareas de Deep Learning y ofrecen algunas funcionalidades adicionales optimizadas para la diferenciación automática durante backpropagation. Aquí hay algunas operaciones comunes que los tensores pueden hacer:

- **Operaciones matemáticas**: Los tensores admiten operaciones matemáticas estándar, como suma, resta, multiplicación, división y operaciones por elementos, como multiplicación por elementos, división por elementos, etc.
- **Reshaping**: Los tensores se pueden remodelar para cambiar sus dimensiones, lo que le permite convertir un tensor 1D en un tensor 2D, o viceversa.